ภาคผนวก M

การทดลองที่ 13 การพัฒนาอัลกอริธึมแบบขนานด้วยไลบรารี OpenMP

การพัฒนาอัลกอริธึมแบบขนานบนซีพียูชนิดมัลติคอร์ในปัจจุบันจำเป็นต้องอาศัยภาษาคอมพิวเตอร์ระดับสูง เช่น ภาษา C/C++ ภาษา Java เป็นต้น เพื่อช่วยลดเวลารัน (Run Time) ซึ่งเท่ากับเร่งความเร็ว (Speedup) ให้อัลกอริธึมหรือโปรแกรม โดยการสร้างเธรดผู้ช่วย (Worker Thread) และมอบหมายงานให้ไปรันบนแกนประมวลผลที่ยังว่างอยู่ ผู้อ่านสามารถประยุกต์ใช้หลักการนี้บนเครื่องคอมพิวเตอร์ทั่วไปจนถึงเครื่องซูเปอร์คอมพิวเตอร์ตามเนื้อหาในบทที่ 8 ดังนั้น การทดลองมีวัตถุประสงค์ดังนี้

- เพื่อพัฒนาโปรแกรมภาษา C ด้วยไลบรารี OpenMP ให้สามารถทำงานแบบมัลติเธรดและใช้งานซีพียูชนิดมัลติคอร์ได้เต็มที่
- เพื่อเรียนรู้การวัด CPU Utilization (%CPU) เวลาจริง (T_{real}) เวลาผู้ใช้ (T_{user}) และเวลาระบบ (T_{sys}) ในซีพียูชนิดมัลติคอร์
- เพื่อทำความเข้าใจการวัดประสิทธิภาพของอัลกอริธึมแบบขนานจากการประเมินความซับซ้อนเชิงเวลาด้วยพีชคณิต BigO ที่มา: Rosen (2002) และตัวชี้วัด Speedup ที่มา: Patterson and Hennessy (2016) จากเวลาที่วัดได้

M.1 การวัด CPU Utilization

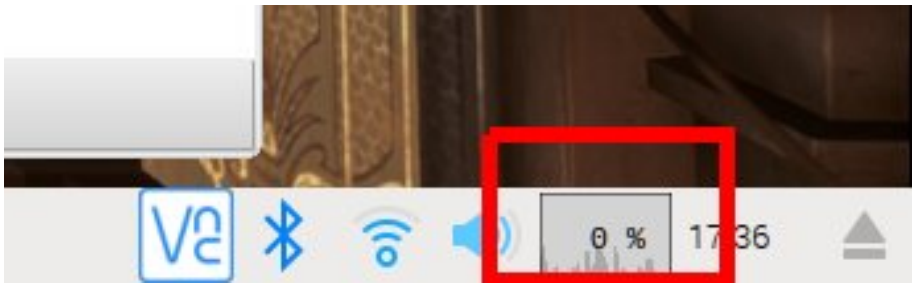

รูปที่ M.1: กราฟแสดงการใช้งานซีพียู (CPU Usage Monitor) ย้อนหลังและค่าสรุป ณ เวลาปัจจุบัน ที่มา: abload.de

CPU

Intel(R) Core(TM) i7-8550U CPU @ 1.80GHz

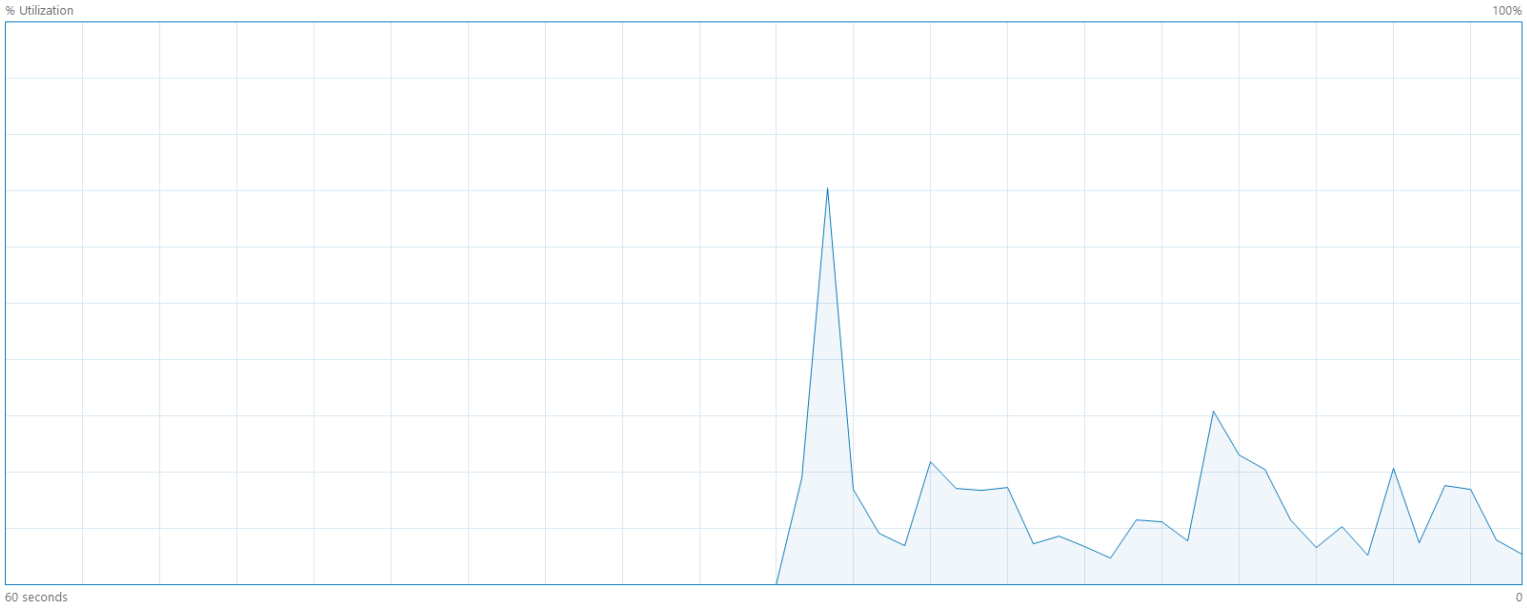

Utilization	Speed	Processes	Threads	Handles
5%	3.82 GHz	230	2874	117274

Base speed:	1.99 GHz
Sockets:	1
Cores:	4
Logical processors:	8
Virtualization:	Enabled

ผู้อ่านสามารถติดตั้งเครื่องมือและกราฟในรูปที่ M.1 แสดงการใช้งานซีพียู (CPU Usage Monitor) ย้อนหลังและค่าสรุป ณ เวลาปัจจุบันของบอร์ด Pi ประกอบการทดลองที่ 13 ตามขั้นตอนเหล่านี้

1. เลื่อนเมาส์ไปบนตำแหน่งว่างของ Task Bar
2. คลิกขวา เพื่อให้เมนูต่อไปนี้ปรากฏขึ้นแล้วคลิกซ้ายเลือก Add/Remove Panel Items
3. คลิกที่แท็บ Panel Applets
4. เลื่อนรายการขึ้นลงเพื่อหารายการชื่อ CPU Usage Monitor แล้วคลิก Add
5. กดปุ่ม Up และ Down เพื่อวางตำแหน่งของ CPU Usage Monitor ในตำแหน่งที่ต้องการ โปรดสังเกตรายชื่อ เมื่อได้ตำแหน่งที่ต้องการแล้วกด Close หมายเหตุ **Spacer** หมายถึง ช่องว่างที่คั่นระหว่าง Applet ที่อยู่บน Task Bar
6. สังเกตด้านขวาของ Task Bar จะมีจอสีเทาขนาดเล็กแสดงเป็นกราฟแท่ง โดยแท่งขวาสุดคือ วินาทีล่าสุด
7. เลื่อนเมาส์ไปบนกราฟแล้วคลิกขวาเพื่อเพิ่มการแสดงผลเป็นตัวเลขหน่วยเป็นเปอร์เซ็นต์ (%)
8. ทดสอบการทำงานโดยการเปิดคลิปเดียวกันบน YouTube.com ที่ความละเอียดแตกต่างกัน เช่น 240p, 480p และ 720p ทีละค่าเพื่อให้เห็นค่า $\%CPU_{max}$ ที่แตกต่าง

M.2 การคูณเมทริกซ์แบบขนาน

$$C = A \times B \tag{M.1}$$

การคูณเมทริกซ์เป็นพื้นฐานของการคำนวณพื้นฐานทางวิทยาศาสตร์ และวิศวกรรมศาสตร์ กำหนดให้เมทริกซ์จตุรัส A ขนาด $N \times N$ สามารถเขียนในรูปแบบของอาร์เรย์ 2 มิติในภาษา C/C++ ได้ดังนี้

$$A = \Big(A[i][j]\Big)$$

โดยดัชนีตัวแรก i คือ หมายเลขแถว มีค่าตั้งแต่ 0 ถึง N-1 ดัชนีตัวที่สอง j คือ หมายเลขคอลัมน์ มีค่าตั้งแต่ 0 ถึง N-1 ดังนั้น

$$A = \begin{pmatrix} A[0][0] & A[0][1] & ... & A[0][N-1] \\ A[1][0] & A[1][1] & ... & A[1][N-1] \\ \\ A[N-1][0] & A[N-1][1] & ... & A[N-1][N-1] \end{pmatrix}$$

เมื่อทำความเข้าใจพื้นฐานของเมทริกซ์ในรูปแบบของอาร์เรย์ 2 มิติแล้ว ผู้อ่านสามารถทำการทดลองตามขั้นตอนต่อไปนี้

1. สร้างไดเรกทอรี **/home/pi/asm/Lab13** บนโปรแกรม Terminal ด้วยคำสั่งต่อไปนี้ตามลำดับ

```
$ cd /home/pi/asm
$ mkdir Lab13
```

```
$ cd Lab13
$ nano multMatrix.c
```

2. กรอกโปรแกรมต่อไปนี้ด้วยโปรแกรม nano และบันทึกในไฟล์ชื่อ **multMatrix.c** ในไดเรกทอรีที่สร้างไว้

```
#include <stdio.h>
#include <stdlib.h>
#include <time.h>
#include <omp.h>

#define N 200
float A[N][N], B[N][N], C[N][N]; // matrices of NxN elements

int main () {
/* DECLARING VARIABLES */
int i, j, k; // indices for matrix multiplication
double t_mul; // Multiply time
double start, stop; // start time and stop time

/* FILLING MATRICES WITH RANDOM NUMBERS */
srand ( time(NULL) );
for(i=0;i<N;i++) {
  for(j=0;j<N;j++) {
    A[i][j]= rand();
    B[i][j]= rand();
  }
}
/* MATRIX MULTIPLICATION */
printf("Max number of threads: %i \n",omp_get_max_threads());
#pragma omp parallel
  printf("Number of threads: %i \n",omp_get_num_threads());
  start=omp_get_wtime(); // time measure: start time
  #pragma omp parallel for private(k, j)
    for(i=0;i<N;i++) {
      for(j=0;j<N;j++) {
        C[i][j]=0; // set initial value of resulting matrix C = 0
        for(k=0;k<N;k++) {
          C[i][j]=C[i][j]+A[i][k]*B[k][j];
        }
      }
    }
```

```
    stop=omp_get_wtime(); // time measure: stop time
    t_mul = stop-start; // Multiply time
    printf("Mutiply Time: %2.4f \n",t_mul);

    /* TERMINATE PROGRAM */
    return 0;
}
```

3. exit ออกจากโปรแกรม nano เพื่อคอมไพล์โปรแกรมด้วยคำสั่งต่อไปนี้

```
$ gcc -fopenmp multMatrix.c -o mulMatrix
```

แก้ไขหากมีข้อผิดพลาดจนกว่าจะคอมไพล์โปรแกรมสำเร็จและมีไฟล์ชื่อ mulMultrix

4. ตั้งค่าจำนวนเธรด n=1 ของโปรแกรมด้วยคำสั่งต่อไปนี้

```
$ export OMP_NUM_THREADS=1
```

5. รันโปรแกรมจับเวลาด้วยคำสั่ง time ดังนี้จำนวน 5 ครั้งเพื่อหาค่าเฉลี่ย ขณะทำการทดลองขอให้ผู้อ่านใช้คลิ๊กข้อมือจับเวลาไปพร้อมๆ กัน เพื่อเปรียบเทียบกับค่าของ $T_{mul,n}$ และ T_{real}

```
$ time ./mulMatrix
```

ซึ่งจะรายงานผลการจับเวลาการทำงานของทั้งโปรแกรมในแง่มุมต่างๆ

6. จดบันทึกค่า CPU Utilization สูงสุดหรือ $\%CPU_{max}$ ที่สังเกตได้ หาค่าเฉลี่ยของ $T_{mul,n}$ T_{real} T_{user} และ T_{sys} ที่ได้เป็นวินาทีลงในตารางที่ M.1

ตารางที่ M.1: เวลาและ $\%CPU_{max}$ ของการคูณเมทริซ์ที่ขนาด N และจำนวนเธรดเท่ากับ 1, 2, 4, 8 เธรด

เวลาเฉลี่ย (วินาที)	N=200 (วินาที)	N=400 (วินาที)	N=800 (วินาที)	N=1000 (วินาที)
n=1 เธรด				
$T_{mul,1}$	0.0356	0.3090	2.6586	4.1029
T_{real}	0.0528	0.327	2.6826	4.132
T_{user}	0.0272	0.313	2.6064	4.0312
T_{sys}	0.0096	0.0128	0.0068	0.0068
$\%CPU_{max}$	8.6	15	32.8	33.4
n=2 เธรด				
$T_{mul,2}$	0.0672	0.1603	1.3687	1.995
T_{real}	0.0374	0.1798	1.3974	2.0256
T_{user}	0.0438	0.3254	2.6898	3.9532
T_{sys}	0.0096	0.0096	0.0096	0.0094
$\%CPU_{max}$	8.4	15	50.2	55.4
n=4 เธรด				
$T_{mul,4}$	0.0471	0.1091	0.9195	1.3106
T_{real}	0.0342	0.13	0.947	1.3448
T_{user}	0.0878	0.416	3.5188	4.9818
T_{sys}	0.0068	0.022	0.0096	0.0064
$\%CPU_{max}$	9	21	68.8	75.6
n=8 เธรด				
$T_{mul,8}$	0.01	0.0861	0.7131	1.5796
T_{real}	0.0338	0.1116	0.795	1.6168
T_{user}	0.1126	0.6844	5.595	12.347
T_{sys}	0.0032	0.0282	0.0094	0.019
$\%CPU_{max}$	10.2	27.2	92.2	100

7. เปลี่ยนจำนวนเธรดเท่ากับ n=2 เธรด ด้วยคำสั่งต่อไปนี้

```
$ export OMP_NUM_THREADS=2
```

แล้ววนกลับไปทำข้อ 5 เพื่อกรอกค่าเฉลี่ยเวลาในตารางที่ M.1 จนครบ แล้วจึงเปลี่ยนจำนวนเธรด n=4 และ 8 เธรด

8. เปลี่ยนขนาดข้อมูล N=400 แล้วกลับไปเริ่มทำข้อ 3 จนถึงข้อ 8 จนครบ N= 800 และ 1000

จากตารางที่ M.1 ผู้อ่านสามารถใช้ประกอบการคำนวณประสิทธิภาพการคำนวณแบบขนานในหัวข้อถัดไป

M.3 ความซับซ้อน (Complexity) ของการคำนวณ

ความซับซ้อนเชิงเวลา (Run Time Complexity) ของการคูณเมทริกซ์เท่ากับ $O(N^3)$ ในทางทฤษฎี ผู้อ่านสามารถประยุกต์ใช้อัตราส่วนระหว่างระหว่าง $O(N_2^3)$ และ $O(N_1^3)$ ที่ภาระงานขนาด N_2:N_1 และจำนวน n เธรดเหมือนกัน เพื่อวัดความซับซ้อนของอัลกอริธึมได้ดังสมการต่อไปนี้

$$\frac{O(N_2^3)}{O(N_1^3)} = \frac{T_{mul,N_2}}{T_{mul,N_1}} \tag{M.2}$$

สำหรับการคูณเมทริกซ์ $T_{mul,N}$ คือ เป็นระยะเวลาเฉลี่ยของการคูณเมทริกซ์ขนาด $N \times N$ ด้วยจำนวน n เธรด จากหัวข้อที่ผ่านมา ผู้อ่านสามารถคำนวณค่าอัตราส่วนของเวลาในตารางที่ M.2 เพื่อใช้วิเคราะห์ต่อไป

ตารางที่ M.2: อัตราส่วนเวลาการคูณเมทริซ์ที่ขนาด N และเวลาที่ขนาด 200 ที่จำนวนเธรดเท่ากับ 1, 2, 4, 8 เธรด จากสมการที่ (M.2)

	N=200	N=400	N=800	N=1000
n=1 เธรด				
$T_{N,1}/T_{200,1}$	1.00	8.68	74.68	115.25
$\sqrt[2]{T_{N,1}/T_{200,1}}$	1.00	2.95	8.64	10.74
$\sqrt[3]{T_{N,1}/T_{200,1}}$	1.00	2.06	4.21	4.85
n=2 เธรด				
$T_{mul,N}/T_{mul,200}$	1.00	2.39	20.38	29.69
$\sqrt[2]{T_{mul,N}/T_{mul,200}}$	1.00	1.55	4.51	5.45
$\sqrt[3]{T_{mul,N}/T_{mul,200}}$	1.00	1.34	2.73	3.1
n=4 เธรด				
$T_{mul,N}/T_{mul,200}$	1.00	2.27	19.48	29.83
$\sqrt[2]{T_{mul,N}/T_{mul,200}}$	1.00	1.51	4.41	5.28
$\sqrt[3]{T_{mul,N}/T_{mul,200}}$	1.00	1.31	2.69	3.03
n=8 เธรด				
$T_{mul,N}/T_{mul,200}$	1.00	86.1	71.31	157.96
$\sqrt[2]{T_{mul,N}/T_{mul,200}}$	1.00	2.93	8.44	12.57
$\sqrt[3]{T_{mul,N}/T_{mul,200}}$	1.00	2.05	4.15	5.41

M.4 ประสิทธิภาพ (Performance) ของการคำนวณแบบขนาน

ผู้อ่านสามารถวัดประสิทธิภาพ (Performance) ของอัลกอริธึมใดๆ ได้จากอัตราส่วนของเวลาเดิม (T_{old}) และเวลาใหม่ (T_{new}) ที่ได้ทำการปรับปรุงอัลกอริธึมนั้นๆ ที่มา: Patterson and Hennessy (2016)

$$\frac{Perf_{new}}{Perf_{old}} = \frac{T_{old}}{T_{new}} \tag{M.3}$$

ดังนั้น ประสิทธิภาพของการคำนวณแบบแบบขนานสามารถวัดได้จากอัตราส่วนระหว่างระยะเวลา $T_{alg,1}$ ของ 1 เธรดและ $T_{alg,n}$ ของ n เธรด และตั้งชื่อเรียกว่า $Speedup(n)$ ด้วยสมการต่อไปนี้

$$Speedup(n) = \frac{T_{alg,1}}{T_{alg,n}} \tag{M.4}$$

โดย $T_{alg,n}$ คือ ช่วงการรันโปรแกรมอัลกอริธึมด้วยจำนวน n เธรด โดยไม่รวมช่วงเวลาอื่นๆ ซึ่งไม่ได้เกี่ยวข้องกับการอัลกอริธึมแบบขนาน ผู้อ่านสามารถประยุกต์ตัวชี้วัดนี้กับอัลกอริธึมการคูณเมทริกซ์ ดังนี้

$$Speedup(n) = \frac{T_{mul,1}}{T_{mul,n}} \tag{M.5}$$

โดย $T_{mul,n}$ คือ ช่วงการรันโปรแกรมคำนวณเมทริกซ์จริงๆ ด้วยจำนวน n เธรด ที่ขนาด N เท่ากันโดยไม่รวมช่วงเวลาสุ่มค่าตั้งต้น และการแสดงผลอื่นๆ ผู้อ่านคำนวณค่า $Speedup(n)$ และกรอกในตารางที่ M.3 เพื่อวิเคราะห์ผลการคำนวณที่ได้โดยตอบคำถามในกิจกรรมท้ายการทดลอง

ตารางที่ M.3: ผลการคำนวณ $Speedup(n)$ ของการคูณเมทริซ์ที่ขนาด N และจำนวนเธรดเท่ากับ 2, 4, 8 เธรด เทียบกับ 1 เธรดด้วยสมการที่ (M.5)

Speedup	N=200	N=400	N=800	N=1000
n=2 เธรด $Speedup(2) = T_{mul,1}/T_{mul,2}$	0.53	1.93	1.94	2.06
n=4 เธรด $Speedup(4) = T_{mul,1}/T_{mul,4}$	0.76	2.89	2.9	3.13
n=8 เธรด $Speedup(8) = T_{mul,1}/T_{mul,8}$	3.56	3.59	3.73	2.6

M.5 กิจกรรมท้ายการทดลอง

1. เหตุใดการทดลองจึงต้องใช้การหาค่าเฉลี่ยเวลาต่างๆ
2. T_{sys} หมายถึง เวลาซีพียูทำงานประเภทไหน
3. T_{user} หมายถึง เวลาซีพียูทำงานประเภทไหน
4. T_{real} มีความสัมพันธ์กับ T_{mul} อย่างไร
5. T_{user} มีความสัมพันธ์กับ T_{mul} และจำนวนเธรด n อย่างไร
6. เมื่อ N_1=200 จงเปรียบเทียบค่าผลการคำนวณของ $\sqrt[2]{T_{mul,N_2}/T_{mul,200}}$ และ $\sqrt[3]{T_{mul,N_2}/T_{mul,200}}$ ที่ได้ในตารางที่ M.2 เมื่อ N_2= 400, 800 และ 1000 และ n= 1, 2, 4 และ 8 เธรดตามลำดับ ว่ามีค่าใกล้เคียงกับ $N_2/200$= 2, 4, 5 ตามลำดับอย่างไร เพราะเหตุใด
7. จำนวนเธรด และ จำนวนแกนประมวลผล มีผลต่อค่า Speedup อย่างไร วิเคราะห์ทั้งหมด 3 กรณีดังนี้
   - จำนวนเธรด < จำนวนแกนประมวลผล
   - จำนวนเธรด = จำนวนแกนประมวลผล
   - จำนวนเธรด > จำนวนแกนประมวลผล
8. เหตุใดค่าเฉลี่ยเวลา T_{user} จึงไม่แตกต่างกัน ที่ N คงที่
9. เวลาส่วนใหญ่ของการรัน T_{real} T_{user} และ T_{sys} สัมพันธ์กันอย่างไร จงสร้างสมการ
10. จำนวนเธรดที่เพิ่มขึ้นทำให้การคำนวณเร็วขึ้นอย่างไร มีข้อจำกัดหรือไม่
11. ที่ขนาดข้อมูล N=1000 จำนวนเธรดที่เพิ่มขึ้นทำให้ T_{user} เปลี่ยนแปลงอย่างไร มีข้อจำกัดหรือไม่
12. ที่ขนาดข้อมูล N ต่างๆ ค่า $\%CPU_{max}$ มีการเปลี่ยนแปลงและมีความสัมพันธ์กับจำนวนเธรด n อย่างไร
13. ขนาดข้อมูล N ที่เพิ่มขึ้นมีผลต่อ $Speedup(n)$ ที่ n=1, 2, 4 และ 8 หรือไม่ อย่างไร

⑥ เมื่อ $n=1$, ในทุกๆ N_2 $\sqrt[2]{T_{mul,N_2}/T_{mul,200}}$ จะมีค่ามากกว่า $N_2/200$
ส่วน $\sqrt[3]{T_{mul,N_2}/T_{mul,200}}$ จะมีค่าใกล้เคียงกับ $N_2/200$ เพราะ อัตราการเพิ่มของเวลา มีค่าใกล้กับอัตราการเพิ่มของ N_2

เมื่อ $n=2$, ในทุกๆ N_2 $\sqrt[2]{T_{mul,N_2}/T_{mul,200}}$ จะมีค่าใกล้เคียงกับ $N_2/200$

$\sqrt[3]{T_{mul,N_2}/T_{mul,200}}$ จะมีค่าน้อยกว่า $N_2/200$ เพราะอัตราการเพิ่มของเวลามีค่าน้อยกว่าอัตราการเพิ่มของ N_2

เมื่อ $n=4$ คุณลักษณะคล้ายกับ $n=2$

เมื่อ $n=8$, ในทุกๆ N_2 $\sqrt[2]{T_{mul,N_2}/T_{mul,200}}$ จะมีค่ามากกว่า $N_2/200$
ส่วน $\sqrt[3]{T_{mul,N_2}/T_{mul,200}}$ จะมีค่าใกล้เคียงกับ $N_2/200$
เพราะ อัตราการเพิ่มของเวลามีค่าใกล้เคียงกับอัตราการเพิ่มของ N_2

⑦ เมื่อ จำนวนเธรด < จำนวนแกน เมื่อเพิ่มเธรด จะทำให้เวลาการทำงานเร็วลง (speed up มากขึ้น)

เมื่อ จำนวนเธรด = จำนวนแกน จะมีค่า speed up มากกว่ากรณีที่เธรด<แกน แต่จะมากกว่าหรือน้อยกว่ากรณี เธรด>แกน

เมื่อ จำนวนเธรด > จำนวนแกน ส่วนใหญ่ค่า speed up จะสูงกว่าเธรด=แกน จะมีบางกรณีที่ค่า speed up น้อยกว่าเธรด=แกน แต่ยังมากกว่าเธรด<แกน